


Навчання з підкріпленням

Лекція 4: Безмодельне передбачення

Кочура Юрій Петрович iuriy.kochura@gmail.com @y_kochura

Огляд



- Навчання з підкріпленням це наука про те, як навчитися приймати правильні рішення
- Агент може вивчати стратегію, функцію цінності та/або модель
- Загальна проблема передбачає врахування часу та наслідків
- Прийняті рішення впливають на винагороду, стан агента та стан середовища

Сьогодні

- Вступ до безмодельного передбачення
- Методи Монте-Карло
- Методи часових різниць (temporal difference, TD)
- $\mathsf{TD}(\lambda)$: Покращена оцінка усіх відвіданих станів

- Минулого разу
 - Планування за допомогою динамічного програмування
 - Розв'язок відомого МППР
- Сьогодні
 - Безмодельне передбачення
 - Оцінка функції цінності невідомого МППР

Вступ до безмодельного передбачення

Агенти, які навчаються на зворотному зв'язку (методом проб і помилок) часто відносять до задач передбачення, тому що ми маємо оцінити функцію цінності, яка показує очікувану (середню) винагороду агента для певно стратегії. Функція цінності містить значення, які залежать від майбутнього, тому в певному сенсі ми вчимося передбачати майбутнє.

Винагорода R_t : скалярний сигнал, який отримує агент у якості зворотного зв'язку від середовища після виконання дії агеном. Відноситься до однокрокового сигналу: агент спостерігає за станом середовища, обирає дію та отримує сигнал винагороди. Миттєва винагорода є ключовим поняттм в RL, але це не те, що агент намагається максимізувати.


Загальна винагорода (return): сумарна винагорода отримана агентом з моменту часу t з урахування знецінювання γ . Розраховується від будь-якого стану агента і зазвичай триває до кінця епізоду. Тобто, коли досягається стан завершення (terminal state), обчислення припиняється.

$$G_t = R_{t+1} + \gamma R_{t+2} + \cdots = \sum_{k=0}^\infty \gamma^k R_{t+k+1}$$

Функція цінності: визначає усереднену загальну винагороду:

$$egin{aligned} v(s) &= \mathbb{E}\left[G_t \mid S_t = s
ight] = \ &= \mathbb{E}\left[R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \cdots \mid S_t = s
ight] \end{aligned}$$

Середовище випадкового блукання



Методи Монте-Карло (МК)

- Методи МК вчаться безпосередньо з епізодів (досвіду)
- МК методи безмодельні: відсутні знання про МППР
- Методи МК навчаються з повних епізодів: без бутстрапінга
- Ми називаємо пряму вибірку епізодів Монте-Карло
- Примітка: методи МК можна застосовувати лише до епізодичних МППР
 - Усі епізоди мають бути кінцевими
- Методи МК використовують просту ідею: цінність = середня загальна винагорода

Оцінка стратегії Монте-Карло

ullet Мета: вивчити $v_\pi(s)$ з епізодів досвіду в рамках стратегії π

$$S_t, A_t, R_{t+1}, \cdots, S_T \sim \pi$$

• Загальна винагорода:


$$G_{t:T} = R_{t+1} + \gamma R_{t+2} + \dots + \gamma^{T-1} R_T$$

• Функція цінності:

$$v_\pi(s) = \mathbb{E}_\pi \left[G_t \mid S_t = s
ight]$$

Перше відвідування Монте-Карло (First-visit Monte Carlo, FVMC): покращення оцінок після кожного епізоду

Monte Carlo prediction



FVMC

1.
$$v_\pi(s) = \mathbb{E}_\pi \left[G_t \mid S_t = s
ight]$$

2.
$$G_{t:T} = R_{t+1} + \gamma R_{t+2} + \cdots + \gamma^{T-1} R_T$$

3.
$$S_t, A_t, R_{t+1}, \cdots, R_T, S_T \sim \pi$$

4.
$$T_T(S_t) = T_T(S_t) + G_{t:T}$$

$$5.N_T(S_t) = N_T(S_t) + 1$$

6.
$$V_T(S_t) = rac{T_T(S_t)}{N_T(S_t)}$$

7. Якщо $N(s) o \infty$, тоді $V(s) o v_\pi(s)$

$$oxed{V_T(S_t) = V_{T-1}(S_t) + rac{1}{N_t(S_t)}igg[G_{t:T} - V_{T-1}(S_t)igg]}$$

$$V_T(S_t) = V_{T-1}(S_t) + lpha_tigg[\underbrace{G_{t:T}}_{ ext{MC target}} - V_{T-1}(S_t) igg]$$

Кожне відвідування Монте-Карло (Every-visit Monte Carlo, EVMC): інший спосіб обробки відвіданих станів

Ви, напевно, помітили, що на практиці можна реалізувати два різних способи алгоритму з усереднення загальної винагороди. Це викликано тим, що одна траєкторія може містити кілька відвідувань одного і того ж стану. У цьому випадку, чи варто розраховувати загальну винагороду після кожного з цих відвідувань незалежно, а потім включити всі ці значення до усереднення, чи ми повинні використовувати обраховану загальну винагороду лише від першого візиту до кожного стану?

Обидва підходи є робочими та мають схожі теоретичні властивості.

Перше **vs** Кожне відвідування Монте-Карло

Передбачення МК оцінює $v_\pi(s)$ як усереднене значення загальних винагород при дотриманні стратегії π . FVMC використовує лише одне значення загальної винагороди для одного стану протягом епізоду: загальна винагорода після першого відвідування стану. EVMC усереднює загальну винагороду для усіх відвідувань одного і того ж стану протягом епізоду.

Історія

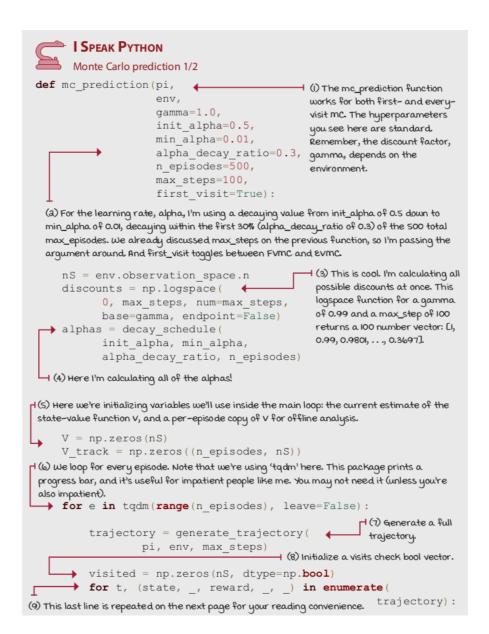
Ви, напевно, чули раніше термін "симуляції Монте-Карло" або "імітаційне моделювання". Методи Монте-Карло, загалом відомі з 1940-х років і є широким класом алгоритмів, які використовують випадкову вибірку для оцінок. Проте, у 1996 році вперше методи першого та кожного відвідування МК були визначені у статті Сатіндера Сінгха (Satinder Singh) та Річарда Саттона "Reinforcement Learning with Replacing Eligibility Traces".

I SPEAK PYTHON

Exponentially decaying schedule

```
(1) This function allows
def decay schedule (init value, min value,
                                                        you to calculate all the
                      decay ratio, max steps,
                                                        values for alpha for the
                      log start=-2, log base=10):
                                                        full training process.
    decay steps = int(max steps * decay ratio)
    rem steps = max steps - decay steps
 (a) First, calculate the number of steps to decay the values using the decay_ratio variable.
 (3) Then, calculate the actual values as an inverse log curve. Notice we then normalize
 between 0 and 1, and finally transform the points to lay between init_value and min_value.
    values = np.logspace(log start, 0, decay steps,
                             base=log base, endpoint=True)[::-1]
    values = (values - values.min()) / \
                                      (values.max() - values.min())
    values = (init value - min value) * values + min value
    values = np.pad(values, (0, rem steps), 'edge')
    return values
```

```
I SPEAK PYTHON
      Generate full trajectories
def generate trajectory(pi, env, max steps=20):
                                       🕇 (1) This is a straightforward function. It's
    done, trajectory = False, []
                                         running a policy and extracting the collection
    while not done:
                                         of experience tuples (the trajectories) for
         state = env.reset()
                                         off-line processing.
         for t in count():
              action = pi(state)
              next state, reward, done, = env.step(action)
              experience = (state, action, reward,
                              next state, done)
              trajectory.append(experience)
              if done:
                                          1 (a) This allows you to pass a maximum
                   break
                                           number of steps so that you can
              if t \ge max steps - 1:
                                           truncate long trajectories if desired.
                   trajectory = []
                   break
              state = next state
    return np.array(trajectory, np.object)
```



```
I SPEAK PYTHON
       Monte Carlo prediction 2/2
  → (10) This first line is repeated on the previous page for your reading convenience.
      for t, (state, _, reward, _, _) in enumerate(
                                                                trajectory):
    (11) We now loop through all experiences in the trajectory.
    (1a) Check if the state has already been visited on this trajectory, and doing FVMC.
              if visited[state] and first visit:
                    continue (

√ (13) And if so, we

               visited[state] = True
                                                           process the next state.
\dashv (14) If this is the first visit or we are doing evmc, we process the current state.
 (15) First, calculate the number of steps from t to T.
               n steps = len(trajectory[t:]) 	—
 (16) Then,
            G = np.sum(discounts[:n_steps] * trajectory[t:, 2])
 calculate
             V[state] = V[state] + alphas[e] * (G - V[state])
                               (17) Finally, estimate the value function.
          V_track[e] = V (18) Keep track of the episode's v.
     return V. copy (), V track (19) And return V, and the tracking when done.
```

WITH AN RL ACCENT Incremental vs. sequential vs. trial-and-error

Incremental methods: Refers to the iterative improvement of the estimates. Dynamic programming is an incremental method: these algorithms iteratively compute the answers. They don't "interact" with an environment, but they reach the answers through successive iterations, incrementally. Bandits are also incremental: they reach good approximations through successive episodes or trials. Reinforcement learning is incremental, as well. Depending on the specific algorithm, estimates are improved on an either per-episode or per-time-step basis, incrementally.

Sequential methods: Refers to learning in an environment with more than one non-terminal (and reachable) state. Dynamic programming is a sequential method. Bandits are not sequential, they are one-state one-step MDPs. There's no long-term consequence for the agent's actions. Reinforcement learning is certainly sequential.

Trial-and-error methods: Refers to learning from interaction with the environment. Dynamic programming is not trial-and-error learning. Bandits are trial-and-error learning. Reinforcement learning is trial-and-error learning, too.

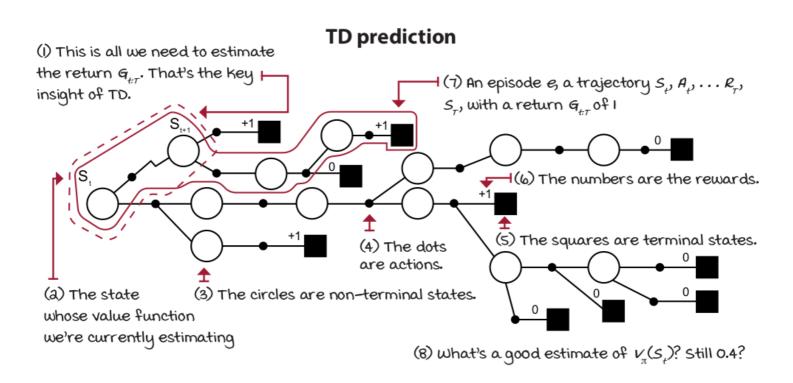
Методи часових різниць (temporal difference, TD)

WITH AN RL ACCENT True vs. actual vs. estimated

True value function: Refers to the exact and perfectly accurate value function, as if given by an oracle. The true value function is the value function agents estimate through samples. If we had the true value function, we could easily estimate returns.

Actual return: Refers to the experienced return, as opposed to an estimated return. Agents can only experience actual returns, but they can use estimated value functions to estimate returns. Actual return refers to the full experienced return.

Estimated value function or estimated return: Refers to the rough calculation of the true value function or actual return. "Estimated" means an approximation, a guess. True value functions let you estimate returns, and estimated value functions add bias to those estimates.



Методи часових різниць (ТD) та бутстрапінг

TD методи оцінюють $v_{\pi}(s)$ з використанням оцінки $v_{\pi}(s)$. Це підхід відомий як бутстрапінг, робить здогадку з здогадки; він використовує оціночну загальну винагороду замість фактичної. Формально цей метод використовує:

$$R_{t+1} + \gamma V_t(S_{t+1})$$

для розрахунку та оцінки $V_{t+1}(S_t)$.

Оскільки TD використовує один крок фактичного значення загальної винагороди R_{t+1} , він усе ще працюватиме добре. Цей сигнал винагороди R_{t+1} поступово «вносить реальність» в оцінки.



Show Me the Math

Temporal-difference learning equations

- (1) We again start from the definition of the $v_{\pi}(s) = \mathbb{E}_{\pi}[G_{t:T} \mid S_t = s]$ state-value function ... -
- (a) ... and the definition of the return.

$$G_{t:T} = R_{t+1} + \gamma R_{t+2} + \dots + \gamma^{T-1} R_T$$

(3) From the return, we can rewrite the equation by grouping up some terms. Check it out. >

$$G_{t:T} = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots + \gamma^{T-1} R_T$$

$$= R_{t+1} + \gamma (R_{t+2} + \gamma R_{t+3} + \dots + \gamma^{T-2} R_T)$$

 $=R_{t+1}+\gamma G_{t+1:T}$ (4) Now, the same return has a recursive style.

(5) We can use this new definition to also rewrite the state-value function definition equation.

$$v_{\pi}(s) = \mathbb{E}_{\pi}[G_{t:T} \mid S_t = s] \tag{6} \text{ And because the expectation of the returns from the next state is the state-} \\ = \mathbb{E}_{\pi}[R_{t+1} + \gamma G_{t+1:T} \mid S_t = s] \tag{9} \text{ And because the expectation of the returns from the next state is the state-} \\ = \mathbb{E}_{\pi}[R_{t+1} + \gamma v_{\pi}(S_{t+1}) \mid S_t = s] \tag{9} \text{And because the expectation of the returns from the next state, we get this.} \\ = \mathbb{E}_{\pi}[R_{t+1} + \gamma v_{\pi}(S_{t+1}) \mid S_t = s] \tag{9} \text{And because the expectation of the returns from the next state, we get this.} \\ = \mathbb{E}_{\pi}[R_{t+1} + \gamma v_{\pi}(S_{t+1}) \mid S_t = s] \tag{9} \text{And because the expectation of the returns from the next state, we get this.} \\ = \mathbb{E}_{\pi}[R_{t+1} + \gamma v_{\pi}(S_{t+1}) \mid S_t = s] \tag{9} \text{And because the expectation of the returns from the next state is the state-} \\ = \mathbb{E}_{\pi}[R_{t+1} + \gamma v_{\pi}(S_{t+1}) \mid S_t = s] \tag{9} \text{And because the expectation of the returns from the next state is the state-} \\ = \mathbb{E}_{\pi}[R_{t+1} + \gamma v_{\pi}(S_{t+1}) \mid S_t = s] \tag{9} \text{And because the expectation of the returns from the next state is the state-} \\ = \mathbb{E}_{\pi}[R_{t+1} + \gamma v_{\pi}(S_{t+1}) \mid S_t = s] \tag{9} \text{And because the expectation of the returns from the next state is the state-} \\ = \mathbb{E}_{\pi}[R_{t+1} + \gamma v_{\pi}(S_{t+1}) \mid S_t = s] \tag{9} \text{And because the expectation of the returns from the next state-} \\ = \mathbb{E}_{\pi}[R_{t+1} + \gamma v_{\pi}(S_{t+1}) \mid S_t = s] \tag{9} \text{And because the expectation of the returns from the next state-} \\ = \mathbb{E}_{\pi}[R_{t+1} + \gamma v_{\pi}(S_{t+1}) \mid S_t = s] \tag{9} \text{And because the expectation of the returns from the next state-} \\ = \mathbb{E}_{\pi}[R_{t+1} + \gamma v_{\pi}(S_{t+1}) \mid S_t = s] \tag{9} \text{And because the expectation of the returns from the next state-} \\ = \mathbb{E}_{\pi}[R_{t+1} + \gamma v_{\pi}(S_{t+1}) \mid S_t = s] \tag{9} \text{And because the expectation of the returns from the next state-} \\ = \mathbb{E}_{\pi}[R_{t+1} + \gamma v_{\pi}(S_{t+1}) \mid S_t = s] \tag{9} \text{And because the expectation of the next state-} \\ = \mathbb{E}_{\pi}[R_{t+1} + \gamma v_{\pi}(S_{t+1}) \mid S_t = s] \tag{9} \text{And because the expectation of the next state-} \\ = \mathbb{E}$$

expectation of the returns from the next value function of the


(6) And because the

(7) This means we could estimate the state-value function on every time step.

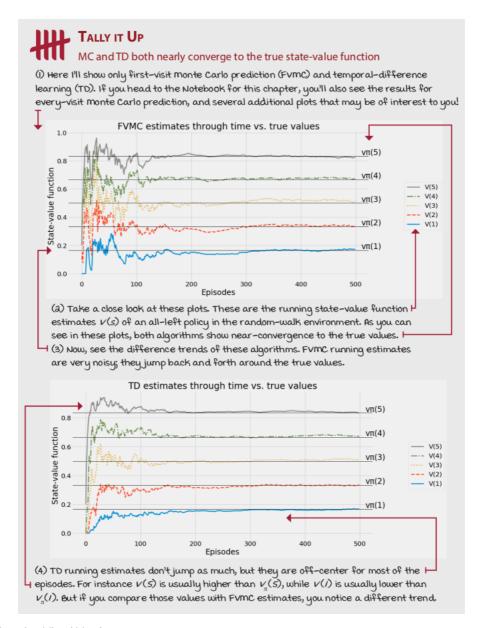
 $S_t, A_t, R_{t+1}, S_{t+1} \sim \pi_{t:t+1}$

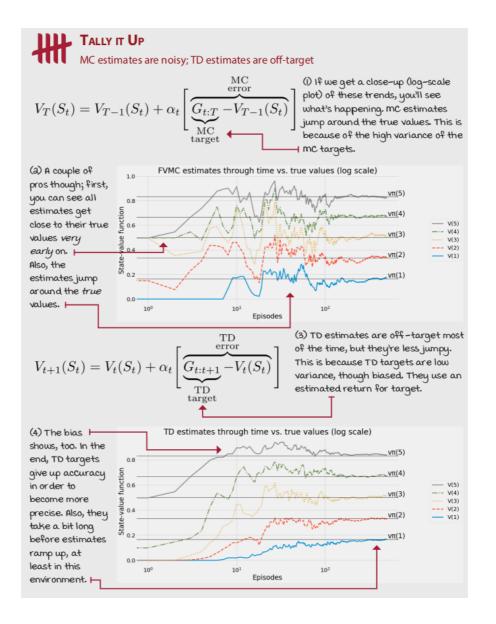
(8) We roll out a single interaction step ... +

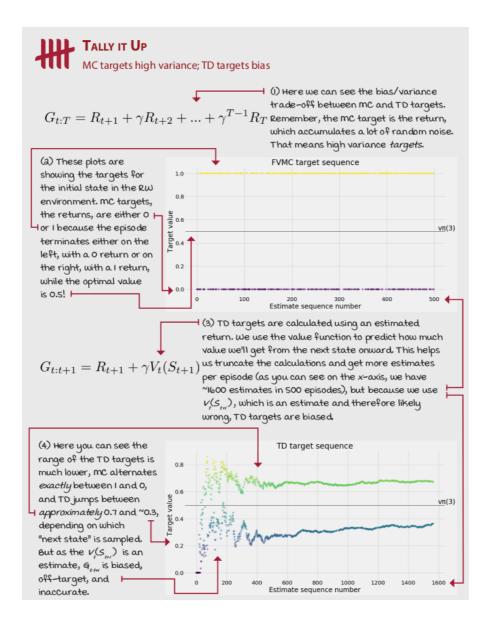
- → (9) ... and can obtain an estimate V(s) of the true state-value function $v_{s}(s)$ a different way than with mc.
- (10) The key difference to realize is we're now estimating $v_s(s_s)$ with an estimate of $v_s(s_s)$. We're using an estimated, not actual, return.



I SPEAK PYTHON The temporal-difference learning algorithm def td(pi, → (1) td is a prediction method. It takes in a env, policy pi, an environment env to interact gamma=1.0, with, and the discount factor gamma. init alpha=0.5, 🕇 (a) The learning method has a min alpha=0.01, configurable hyperparameter alpha, alpha decay ratio=0.3, which is the learning rate. n episodes=500): 🛏 (3) One of the many ways of handling the learning rate is to exponentially decay it. The initial value is init_alpha, min_alpha, the minimum value, and alpha_decay_ratio is the fraction of episodes that it will take to decay alpha from init_alpha to min_alpha. nS = env.observation space.n (4) We initialize the variables needed. V = np.zeros(nS)V track = np.zeros((n episodes, nS)) → (5) And we calculate the alphas = decay_schedule(learning rate schedule init alpha, min alpha, for all episodes ... alpha decay ratio, n episodes) \dashv (6) \dots and loop for n_episodes. for e in tqdm(range(n episodes), leave=False): (7) We get the initial state and then enter the interaction loop. state, done = env.reset(), False while not done: 🕇 (8) First thing is to sample the policy pi for the action to take in state. action = pi(state) (9) We then use the action to interact with the environment... We roll out the policy one step. next_state, reward, done, = env.step(action) (10) We can immediately calculate a target to update the state-value function estimates . . . td target = reward + gamma * V[next state] * \ (**not** done) (11) ... and with the target, an error. (1a) Finally update v(s) ⊢ td error = td target - V[state] V[state] = V[state] + alphas[e] * td error + (13) Don't forget to update the state state = next state variable for the next iteration. Bugs like this can be hard to find V track[e] = V return V, V_track (4) And return the V function and the tracking variable.










Оцінювання функції цінності з кількох кроків

What's in the middle?



N-кроковий **TD**

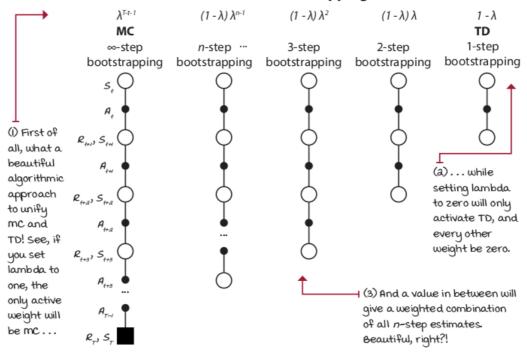




```
N-stepTD 2/2
🖊 (11) Same. Just for you to follow the indentation.
         → while not done and len(path) < n step:</p>
(1a) This is the
                  action = pi(state)
interaction block. - next state, reward, done, = env.step(action)
we're basically
                  experience = (state, reward, next state, done)
collecting experiences path.append (experience)
until we hit done or
                    state = next state
the length of the path if done:
                                            H (13) n here could be 'n_step' but it could
is equal to n_step.
                                               also be a smaller number if a terminal
                                              state is in the 'path.'
               n = len(path)
                                            H (14) Here we're extracting the state
               est_state = path[0][0]←
                                              we're estimating, which isn't state.
       (15) rewards is a vector of all rewards encountered from the est_state until n.
       rewards = np.array(path)[:,1]
       (16) partial_return is a vector of discounted rewards from est_state to n.
           partial return = discounts[:n] * rewards
       (17) bs_val is the bootstrapping value. Notice that in this case next state is correct.
           bs val = discounts[-1] * V[next state] * (not done)
       (18) ntd_target is the sum of the partial return and bootstrapping value.
            ntd target = np.sum(np.append(partial return,
                                                    bs val))
       (19) This is the error, like we've been calculating all along.
            ntd error = ntd target - V[est state]
       (a0) The update to the state-value function
            → V[est state] = V[est state] + alphas[e] * ntd error
       (a1) Here we set path to None to break out of the episode loop, if path has only one
       experience and the done flag of that experience is True (only a terminal state in path.)
               if len(path) == 1 and path[0][3]:
                    path = None
          V track[e] = V
     return V, V track (aa) we return V and V_track as usual.
```

TD(λ): Покращена оцінка усіх відвіданих станів

Generalized bootstrapping



Show Me the Math Forward-view TD(λ)

(1) Sure, this is a loaded equation; we'll unpack it here. The bottom line is that we're using all *n*-step returns until the final step 7, and weighting it with an exponentially decaying value.

$$G_{t:T}^{\lambda} = \underbrace{(1-\lambda)\sum_{n=1}^{T-t-1}\lambda^{n-1}G_{t:t+n}}_{\text{Sum of weighted returns from 1-step to T-1 steps}} \underbrace{\lambda^{T-t-1}G_{t:T}}_{\text{Weighted final return (T)}} \underbrace{\lambda^{T-t-1}G_{t:T}}_{\text{Weighted final return (T)}}$$

(3) All this equation is saying is that we'll calculate the one-step return and weight it with the following factor ... $\longrightarrow 1$ —

(4) \dots and also the two-step return and weight it with this factor. \Box $G_{t:t+2}=R_{t+1}+\gamma R_{t+2}+\gamma^2 V_{t+1}(S_{t+2})$ $(1-\lambda)\lambda$

(S) Then the same for the three-step return and this factor. $G_{t:t+3} = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \gamma^3 V_{t+2}(S_{t+3})$ $(1-\lambda)\lambda^2$

$$G_{t:t+n}=R_{t+1}+\ldots+\gamma^{n-1}R_{t+n}+\gamma^nV_{t+n-1}(S_{t+n}) \qquad (1-\lambda)\lambda^{n-1}$$

 $\mathbf{r}^{(7)}$... until your agent reaches a terminal state. Then you weight by this normalizing factor.

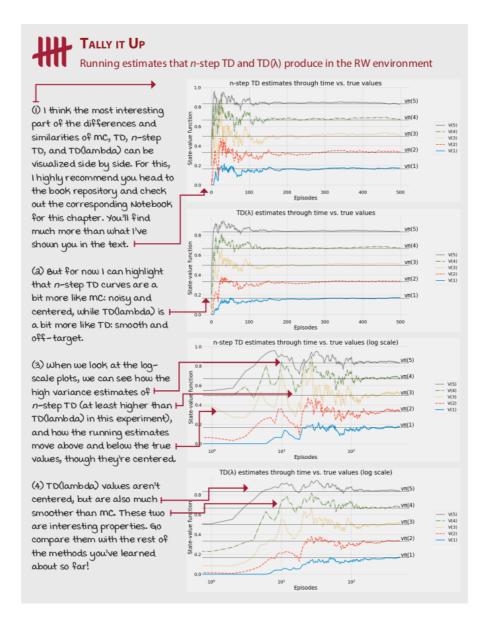
$$G_{t:T} = R_{t+1} + \gamma R_{t+2} + \dots + \gamma^{T-1} R_T$$

(8) Notice the issue with this approach is that you must sample an entire trajectory before you can calculate these values.

an entire trajectory before you can calculate these values. $S_t, A_t, R_{t+1}, S_{t+1}, ..., R_T, S_T \sim \pi_{t:T}$ (9) Here you have it, V will

become available at time
$$\tau$$
 ...
$$V_T(S_t) = V_{T-1}(S_t) + \alpha_t \left[\underbrace{G_{t:T}^{\lambda} - V_{T-1}(S_t)}_{\lambda \text{-return}} \right]$$

```
I SPEAK PYTHON
       The TD(\lambda) algorithm, a.k.a. backward-view TD(\lambda)
def td lambda(pi, +
                                             (i) The method td_lambda has a
                 gamma=1.0,
                                              signature very similar to all other
                 init alpha=0.5,
                                              methods. The only new
                min alpha=0.01,
                                              hyperparameter is lambda_(the
                 alpha decay ratio=0.3,
                                              underscore is because lambda is a
                lambda = 0.3,
                                              restricted Keyword in Python).
                 n episodes=500):
                                             ┥(a) Set the usual suspects.
     nS = env.observation space.n
     V = np.zeros(nS)
    V track = np.zeros((n episodes, nS))
     E = np.zeros (nS) (3) Add a new guy: the eligibility trace vector.
     alphas = decay schedule ( +
         init alpha, min alpha,
                                                    → (4) Calculate alpha
         alpha decay ratio, n episodes)
                                                      for all episodes.
 (5) Here we enter the episode loop.
 for e in tqdm(range(n episodes), leave=False):
         E.fill(0)
                         ——— (6) Set € to zero every new episode.
         state, done = env.reset(), False (7) Set initial variables.
         while not done: (8) Get into the time step loop.
              action = pi(state)
           next_state, reward, done, _ = env.step(action)
       (9) We first interact with the environment for one step and get the experience tuple.
       (10) Then, we use that experience to calculate the TD error as usual.
              td_target = reward + gamma * V[next_state] * \
                                                                (not done)
           td error = td target - V[state]
                                                        - (11) We increment the
                                                         eligibility of state by 1.
              E[state] = E[state] + 1
              V = V + alphas[e] * td error * E ← (la) And apply the error
                                                        update to all eliqible
              E = gamma * lambda * E 🔶
                                                        states as indicated by E.
              state = next state
                                                       — (13) We decay €...
         V track[e] = V
                                                       → (14) ... and continue our
    return V, V track
                                                         lives as usual.
```



Демо

Кінець

Література

• David Silver, Lecture 4: Model-Free Prediction